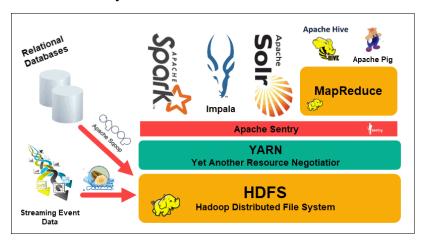
1.Apache Hadoop

Hadoop là một framework cho phép **lưu trữ** và **xử lý** phân tán các tập dữ liệu lớn trên các cụm máy tính bằng cách sử dụng các mô hình lập trình đơn giản. Hadoop được thiết kế để mở rộng quy mô từ các máy chủ đơn lẻ đến hàng nghìn máy, mỗi máy cung cấp tính toán và lưu trữ cục bộ. Tất cả các máy chủ cùng làm việc để lưu trữ và xử lý dữ liệu trên cùng 1 hệ sinh thái duy nhất.



HDFS,YARN và **MapReduce** là trung tâm của hệ sinh thái đó.HDFS là một tập hợp các giao thức được sử dụng để lưu trữ các tập dữ liệu lớn, MapReduce xử lý hiệu quả dữ liệu đó.(tưởng tượng hệ thống như chiếc máy pha café vừa lưu trữ vừa xử lý).

Hadoop Architecture

Một cụm Hadoop bao gồm một hoặc một số MasterNode và nhiều nút khác được gọi là SlaveNode. HDFS và MapReduce tạo thành một nền tảng linh hoạt có thể mở rộng quy mô một cách tuyến tính bằng việc thêm các nút bổ sung. Tuy nhiên, sự phức tạp của dữ liêu lớn có nghĩa là luôn có chỗ để cải thiên.\

Hadoop được chia thành 4 lớp

- Application programming interface(API)
- Processing Framework Layer(Apache Spark, Tez, Mapreduce)
- Cluster Resource Management(YARN)
- Distributed Storage Layer(HDFS)

2.HDFS

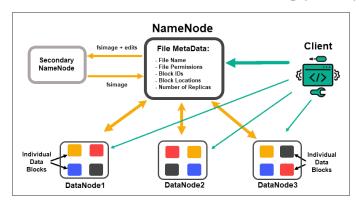
HDFS(Hadoop Distributed File System) là hệ thống lưu trữ dự liệu chính của các ứng dụng Hadoop.HDFS sử dụng kiến trúc NameNode và DataNote để triển khai hệ thống Distributed File. HDFS là một phần quan trọng của nhiều công nghệ hệ sinh thái Hadoop. Nó cung cấp một phương tiện để quản lý các nhóm dữ liệu lớn và hỗ trợ các ứng dụng phân tích dữ liệu lớn liên quan

Lơi ích của HDFS

- Phục hồi nhanh chóng từ các lỗi phần cứng
- Truy cập streaming data
- Nơi lữu trữ của các dư liêu lớn

Datanodes và NameNodes

DataNodes xử lý và lưu trữ các data block,trong khi NameNodes quản lý nhiều DataNotes,duy trì khối siêu dữ liệu(metaData) và kiểm soát quyền truy cập của client.



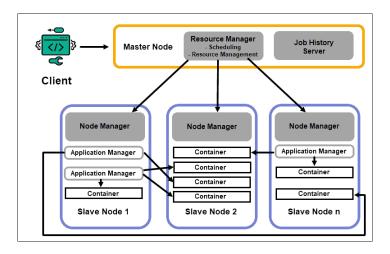
Mỗi DataNode trong một cluster sử dụng một quy trình nền để lưu trữ các data block riêng lẻ trên các slave servers.

Theo mặc định,HDFS lưu trữ ba bản sao của mọi khối dữ liệu trên các DataNodes riêng biệt.NameNode sử dụng rack-aware placement policy giúp datanodes có chứa các bản sao khối dữ liệu không thể được đặt trên cùng một server.

Một DataNode giao tiếp và chấp nhận các hướng dẫn từ NameNode khoảng hai mươi lần một phút. DataNode báo cáo trạng thái và tình trạng của các data block nằm trên Node đó mỗi giờ một lần.NameNode có thể yêu cầu DataNode tạo các bản sao bổ sung, xóa chúng hoặc giảm số lượng khối dữ liệu có trên nút.

3.YARN

YARN(Yet Another Resource Negotiator) là ứng dụng quản lý tài nguyên mặc định của hadoop. Với vai trò phân bổ tài nguyên khiến YARN được đặt giữa lớp lưu trữ(HDFS) và công cụ xử lý(MapReduce). YARN cũng cung cấp một giao diện chung cho phép bạn triển khai các công cụ xử lý mới cho các loại dữ liệu khác nhau.

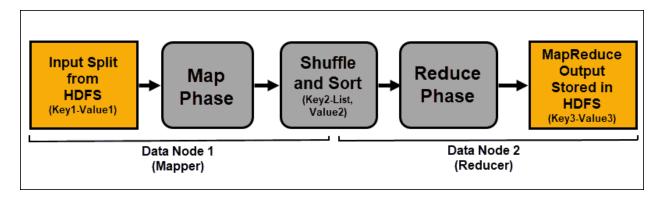


4.MapReduce

MapReduce là một thuật toán lập trình xử lý dữ liệu được phân tán trên cụm Hadoop. Khi tác vụ MapReduce bắt đầu, ResourceManager sẽ yêu cầu một Application Master để quản lý và giám sát vòng đời công việc MapReduce.

Application Master định vị các data block cần thiết dựa trên thông tin được lưu trữ trên NameNode. AM cũng thông báo cho ResourceManager để bắt đầu một tác vụ MapReduce trên cùng một node mà các khối dữ liệu được đặt trên đó. Bất cứ khi nào có thể, dữ liệu được xử lý cục bộ trên các nút phụ để giảm mức sử dụng băng thông và cải thiện hiệu quả của cluster.

Dữ liệu đầu vào được ánh xạ, xáo trộn và sau đó giảm xuống thành kết quả tổng hợp. Đầu ra của tác vụ MapReduce được lưu trữ và sao chép trong HDFS.



Các máy chủ Hadoop thực hiện các tác vụ ánh xạ và giảm thiểu thường được gọi là **Mappers** và **Reducers**.